# Phân tích xu hướng tuyển dụng và kỹ năng việc làm từ dữ liệu lớn LinkedIn năm 2024 (≈ 1,3 triệu tin tuyển dụng)

## I.Bối cảnh

1.1 Sự thay đổi của thị trường lao động trong kỷ nguyên số

Trong những năm gần đây, thị trường lao động toàn cầu đang trải qua những thay đổi mạnh mẽ dưới tác động của chuyển đổi số (Digital Transformation) và sự phát triển nhanh chóng của trí tuệ nhân tạo (Artificial Intelligence – AI). Các công nghệ như Cloud Computing, Big Data Analytics, Machine Learning và tự động hóa quy trình (Automation) đã làm thay đổi cách doanh nghiệp vận hành cũng như nhu cầu tuyển dụng nhân sự.

Trước đây, yêu cầu tuyển dụng thường tập trung vào bằng cấp và kinh nghiệm làm việc. Tuy nhiên, hiện nay doanh nghiệp ngày càng chú trọng vào kỹ năng thực tế (skills-based hiring). Điều này có nghĩa là thay vì hỏi "bạn học trường nào", nhà tuyển dụng quan tâm nhiều hơn đến "bạn làm được gì".

Đặc biệt, sự xuất hiện của các công cụ AI hỗ trợ công việc (ví dụ: AI coding assistant, data automation, chatbot, phân tích dữ liệu tự động) đang làm thay đổi cấu trúc nghề nghiệp. Một số vị trí công việc giảm nhu cầu, trong khi nhiều nghề mới xuất hiện như:

- Data Analyst
- Data Scientist
- AI Engineer
- Cloud Engineer
- Business Intelligence Analyst

Do đó, việc hiểu được doanh nghiệp đang cần kỹ năng gì trở thành vấn đề quan trọng không chỉ đối với sinh viên mà còn đối với nhà trường và người lao động.

## 1.2 Hạn chế của phương pháp khảo sát truyền thống

Thông thường, nghiên cứu thị trường lao động được thực hiện thông qua khảo sát (survey) hoặc phỏng vấn. Tuy nhiên phương pháp này tồn tại nhiều hạn chế:

- Số lượng mẫu nhỏ
- Phụ thuộc vào ý kiến cá nhân
- Không phản ánh chính xác nhu cầu thực tế của doanh nghiệp
- Dữ liệu nhanh chóng lỗi thời

Trong khi đó, mỗi ngày các doanh nghiệp đăng hàng trăm nghìn tin tuyển dụng trực tuyến. Các tin tuyển dụng này thực chất là nguồn dữ liệu trực tiếp thể hiện nhu cầu nhân lực của thị trường.

Vì vậy, thay vì hỏi doanh nghiệp cần gì, có thể phân tích trực tiếp dữ liệu tuyển dụng để xác định xu hướng nghề nghiệp.

## 1.3 Vai trò của nền tảng LinkedIn

LinkedIn là mạng xã hội nghề nghiệp lớn nhất thế giới, với hơn một tỷ người dùng và hàng chục triệu doanh nghiệp tham gia. Đây là nền tảng được sử dụng phổ biến để:

- đăng tuyển dụng
- tìm kiếm nhân sự
- thể hiện hồ sơ nghề nghiệp

Các tin tuyển dụng trên LinkedIn thường bao gồm:

- vị trí công việc
- mô tả công việc
- yêu cầu kỹ năng
- cấp độ kinh nghiệm
- loại hình công việc

Do đó, dữ liệu từ LinkedIn có thể được xem là dữ liệu phản ánh trực tiếp nhu cầu nhân lực của thị trường lao động toàn cầu. Việc khai thác dữ liệu này cho phép nghiên cứu xu hướng nghề nghiệp dựa trên bằng chứng thực tế thay vì suy đoán.

## 1.4 Sự cần thiết của Big Data trong phân tích tuyển dụng

Khối lượng tin tuyển dụng trên LinkedIn là rất lớn, lên tới hàng triệu bản ghi, trong đó phần lớn thông tin quan trọng nằm ở dạng văn bản (job description). Dữ liệu này có các đặc điểm:

- Kích thước lớn (hàng GB dữ liệu)
- Cấu trúc không đồng nhất (structured + unstructured)
- Thay đổi liên tục theo thời gian
- Chứa nhiều thông tin nhiễu

Vì vậy, các phương pháp phân tích dữ liệu truyền thống như Excel hoặc cơ sở dữ liệu thông thường không thể xử lý hiệu quả. Thay vào đó cần áp dụng các kỹ thuật của Big Data và xử lý ngôn ngữ tự nhiên (NLP – Natural Language Processing) để:

- trích xuất kỹ năng từ mô tả công việc
- tổng hợp nhu cầu tuyển dụng
- phát hiện xu hướng nghề nghiệp

## 1.5 Mục tiêu của đề tài

Từ bối cảnh trên, đề tài "Phân tích xu hướng tuyển dụng và kỹ năng việc làm từ dữ liệu lớn LinkedIn năm 2024" được thực hiện nhằm:

1. Phân tích nhu cầu tuyển dụng theo ngành nghề.
2. Xác định các kỹ năng được yêu cầu nhiều nhất trên thị trường lao động.
3. So sánh yêu cầu kỹ năng theo cấp độ kinh nghiệm (intern, junior, senior).
4. Phân tích sự thay đổi xu hướng tuyển dụng theo thời gian.
5. Đề xuất định hướng học tập kỹ năng cho sinh viên ngành CNTT và phân tích dữ liệu.

Kết quả nghiên cứu kỳ vọng cung cấp cái nhìn thực tế về thị trường lao động, hỗ trợ sinh viên lựa chọn lộ trình học tập phù hợp và giúp nhà trường cập nhật chương trình đào tạo theo nhu cầu doanh nghiệp.

# II. Dữ liệu

## 2.1 Nguồn dữ liệu và quy mô

Nhóm sử dụng bộ dữ liệu "1.3M LinkedIn Jobs & Skills (2024)" (Kaggle), phản ánh các tin tuyển dụng được thu thập từ LinkedIn trong năm 2024 và được bổ sung thông tin kỹ năng.

Quy mô dữ liệu (theo Data Explorer):

- Tổng dung lượng: ~6.19 GB
- Tổng số file: 3 file CSV
- Đặc trưng: dữ liệu gồm metadata (có cấu trúc) và văn bản mô tả công việc (không cấu trúc), phù hợp cho bài toán Big Data + NLP.

## 2.2 Danh sách file dữ liệu

Dataset gồm 3 file chính:

(1) linkedin_job_postings.csv (~415.33 MB) — bảng "job postings" (bảng gốc)

- Số cột: 14
- Vai trò: chứa thông tin tổng quan của tin tuyển dụng (tiêu đề, công ty, địa điểm, cấp bậc, loại hình công việc, quốc gia, thời gian…)
- Khóa chính/định danh: job_link (link URL của tin tuyển dụng)

Số lượng bản ghi (quan sát theo unique job_link):

- job_link: ~1,348,454 giá trị duy nhất → tương ứng khoảng 1.35 triệu tin tuyển dụng.

(2) job_summary.csv (~5.1 GB) — bảng "job description" (văn bản mô tả)

- Số cột: 2
- Vai trò: chứa mô tả công việc dạng text (job description) để phục vụ NLP, trích kỹ năng, phân tích nội dung.
- Khóa liên kết: job_link (Foreign Key) liên kết sang linkedin_job_postings.csv

Cấu trúc cột:

- job_link: khóa ngoại
- job_summary: mô tả công việc (kiểu chuỗi, độ dài lớn)

Số lượng (quan sát):

- job_link: ~1,297,332 giá trị duy nhất
- job_summary: ~958,192 giá trị duy nhất
  → cho thấy không phải mọi job_link đều có mô tả, và mô tả có thể trùng/chuẩn hóa giống nhau ở nhiều tin.

(3) job_skills.csv (~672.72 MB) — bảng "skills"

- Số cột: 2
- Vai trò: danh sách kỹ năng đã được trích xuất từ job_summary bằng phương pháp NER (Named Entity Recognition).
- Khóa liên kết: job_link (Foreign Key) liên kết sang linkedin_job_postings.csv

Cấu trúc cột:

- job_link: khóa ngoại
- job_skills: danh sách kỹ năng (dạng chuỗi). Theo mô tả file: cần tách bằng dấu phẩy để chuyển thành list kỹ năng.

Số lượng (quan sát):

- job_link: ~1,296,381 giá trị duy nhất
- job_skills: ~1,287,105 giá trị duy nhất
  → cho thấy không phải mọi tin đều có kỹ năng trích xuất, và có thể có nhiều tin khác nhau có bộ kỹ năng giống nhau.

## 2.3 Data Dictionary (mô tả cột quan trọng)

A. linkedin_job_postings.csv (14 cột)

| Cột | Ý nghĩa |
|---|---|
| job_link | URL tin tuyển dụng trên LinkedIn (định danh tin) |
| last_processed_time | Thời điểm hệ thống xử lý tin gần nhất (timestamp) |

| | |
|---|---|
| got_summary | Có trích xuất được mô tả (job_summary) hay không (bool) |
| got_ner | Có chạy NER để trích kỹ năng hay không (bool) |
| is_being_worked | Tin có đang được xử lý/đánh dấu làm việc hay không (bool) |
| job_title | Tên vị trí tuyển dụng |
| company | Tên công ty đăng tuyển |
| job_location | Địa điểm làm việc (thành phố/tiểu bang/quốc gia tùy tin) |
| first_seen | Thời điểm tin xuất hiện/được ghi nhận lần đầu (timestamp) |
| search_city | Thành phố dùng làm tiêu chí tìm kiếm khi thu thập tin |
| search_country | Quốc gia dùng làm tiêu chí tìm kiếm |
| search_position | Nhóm vị trí/ngành dùng khi tìm kiếm thu thập |
| job_level | Cấp độ (ví dụ: entry-level, associate, mid-senior, …) |
| job_type | Hình thức làm việc (onsite/hybrid/remote/…) |

B. job_summary.csv (2 cột)

| Cột | Ý nghĩa |
|---|---|
| job_link | Khóa ngoại liên kết tin tuyển dụng |
| job_summary | Mô tả công việc dạng văn bản (text dài) |

C. job_skills.csv (2 cột)

| Cột | Ý nghĩa |
|---|---|
| job_link | Khóa ngoại liên kết tin tuyển dụng |
| job_skills | Danh sách kỹ năng trích từ mô tả bằng NER; cần split dấu phẩy để chuẩn hóa |

## 2.4 Mối quan hệ giữa các bảng (Data Model)

Dataset có thể mô hình hóa theo dạng star-like đơn giản:

- linkedin_job_postings.csv là bảng trung tâm (fact/job dimension trung tâm theo job_link)
- job_summary.csv và job_skills.csv là bảng mở rộng theo job_link (1 job ↔ 0/1 summary, 0/1 skills record)

Khóa liên kết chung: job_link

Ý nghĩa:

- Có thể join để tạo "job full record": metadata + summary + skills
- Có thể phân tích theo 2 hướng:
    1. phân tích metadata (job_title, country, level, type…)
    2. phân tích nội dung (job_summary, job_skills)

### 2.5 Đặc điểm chất lượng dữ liệu (Data Quality Observations)

Dựa trên thống kê hiển thị trong Data Explorer:

- Số lượng job_link ở 3 file không bằng nhau
  → nghĩa là không phải mọi tin tuyển dụng đều có summary hoặc skills (thiếu dữ liệu là hợp lý do quá trình crawl/NER).
- job_summary là text lớn (5.1GB)
  → cần xử lý theo batch/chunk hoặc dùng Spark/Parquet để tránh tràn RAM.
- job_skills là danh sách kỹ năng dạng chuỗi
  → cần bước chuẩn hóa: tách list, lower/trim, loại trùng, chuẩn hóa synonym (VD: “PowerBI” vs “Power BI”).

### 2.6 Ý nghĩa dữ liệu đối với mục tiêu đề tài

Với cấu trúc trên, dataset hỗ trợ trực tiếp các mục tiêu:

- Xu hướng tuyển dụng: dùng first_seen, search_country, search_position, job_level, job_type
- Xu hướng kỹ năng: dùng job_skills (đã trích xuất NER), kết hợp theo quốc gia/cấp độ/ngành
- Phân tích sâu nội dung: dùng job_summary để mở rộng (topic modeling, keyword extraction, so sánh JD theo ngành…)

## III. Kiến trúc hệ thống & Data Pipeline

### 3.1 Tổng quan kiến trúc hệ thống

Hệ thống được thiết kế theo kiến trúc Data Lake + Data Warehouse kết hợp xử lý phân tán, gồm các thành phần chính:

- **Storage Layer (Data Lake)**: MinIO
- **Processing Layer**: Apache Spark (PySpark)
- **Streaming Layer**: Apache Kafka
- **Orchestration Layer**: Apache Airflow
- **Serving Layer (Data Warehouse)**: PostgreSQL
- **Visualization Layer**: Microsoft Power BI
- **Containerization**: Docker

**Luồng dữ liệu tổng thể:**

Raw CSV → MinIO (Data Lake) → Spark ETL → Curated Data → PostgreSQL → Power BI Dashboard

Ngoài ra: Kafka dùng để mô phỏng ingestion streaming (job data theo thời gian thực).

3.2 Data Ingestion Layer

### 3.2.1 Batch Ingestion

- Upload 3 file CSV (6.19GB) vào MinIO bucket raw/

- Dữ liệu được chia thành:

  - raw/job_postings/
  - raw/job_summary/
  - raw/job_skills/

Vì job_summary.csv rất lớn (~5.1GB), hệ thống:

- Đọc bằng Spark thay vì pandas
- Chuyển sang định dạng Parquet để:
  - Giảm kích thước
  - Tăng tốc độ query
  - Hỗ trợ partition

### 3.2.2 Streaming Simulation (Kafka)

Để mô phỏng dữ liệu tuyển dụng cập nhật theo thời gian:

- Python Producer đọc từng batch job và gửi vào Kafka topic:
  - linkedin_jobs_stream
- Spark Structured Streaming subscribe topic này
- Dữ liệu được ghi vào:
  - MinIO (bronze layer)
  - PostgreSQL (near real-time table)

Mục tiêu: mô phỏng hệ thống phân tích thị trường lao động real-time.

3.3 Data Storage Design (Data Lake Architecture)

Hệ thống áp dụng mô hình 3-layer:

**Bronze Layer (Raw Data)**

- Dữ liệu giữ nguyên cấu trúc gốc
- Format: Parquet
- Lưu trên MinIO
- Chưa xử lý làm sạch

**Silver Layer (Cleaned Data)**

Thực hiện bằng PySpark:

- Remove null quan trọng (job_title, company)
- Chuẩn hóa:
    - lower case
    - trim whitespace
    - chuẩn hóa kỹ năng ("powerbi" → "power bi")
- Tách job_skills thành array
- Join 3 bảng theo job_link

Output:

job_id

job_title

company

country

job_level

job_type

first_seen

skills_array

job_summary

**Gold Layer (Analytics Ready)**

Tạo các bảng phân tích:

- top_skills_by_country
- skills_by_job_level
- hiring_trend_by_month
- top_job_titles
- skill_demand_growth_rate

Các bảng này được:

- Ghi xuống PostgreSQL
- Kết nối trực tiếp Power BI

3.4 Data Processing & NLP

### 3.4.1 Xử lý

### 3.4.2 Phân tích xu hướng theo thời gian

Dựa vào first_seen:

- Trích xuất:
  - year
  - month
- Tính:
  - số lượng job theo tháng
  - số lượng job theo country + month
  - top skill theo month

Có thể áp dụng:

- Moving Average
- Linear Trend Regression

**3.4.3 Machine Learning Model (Dự đoán)**

Hệ thống xây dựng mô hình dự đoán:

**Bài toán 1: Dự đoán cấp độ công việc (job_level) từ skills**

Input:

- Vector kỹ năng (CountVectorizer / TF-IDF)

Model:

- Logistic Regression / Random Forest

**Bài toán 2: Dự đoán xu hướng tăng trưởng kỹ năng**

- Dùng Time Series Forecast:
    - Linear Regression
    - ARIMA (optional)
    - Prophet (optional)

Output:

- Dự báo skill nào sẽ tăng nhu cầu trong 6 tháng tới.

## 3.5 Orchestration với Airflow

Sử dụng Airflow để tự động hóa pipeline:

DAG gồm các task:

1. ingest_raw_data
2. convert_to_parquet
3. clean_data_spark
4. build_gold_tables
5. load_to_postgres
6. refresh_powerbi_dataset

Lợi ích:

- Tự động chạy theo schedule (daily/weekly)
- Retry khi lỗi
- Monitoring pipeline

## 3.6 Data Warehouse & BI

**PostgreSQL Schema**

Schema đề xuất:

- dim_job
- dim_skill
- fact_job_skill
- fact_job_trend

Power BI kết nối PostgreSQL:

Dashboard gồm:

- Hiring Trend by Month
- Top Skills by Country
- Skills by Experience Level
- Fastest Growing Skills
- Skill vs Job Level Heatmap

## 3.7 Containerization & Deployment

Toàn bộ hệ thống được đóng gói bằng Docker:

- spark container
- kafka container
- zookeeper container
- airflow container
- postgres container
- minio container

Ưu điểm:

- Dễ triển khai
- Môi trường nhất quán
- Dễ mở rộng sang cluster